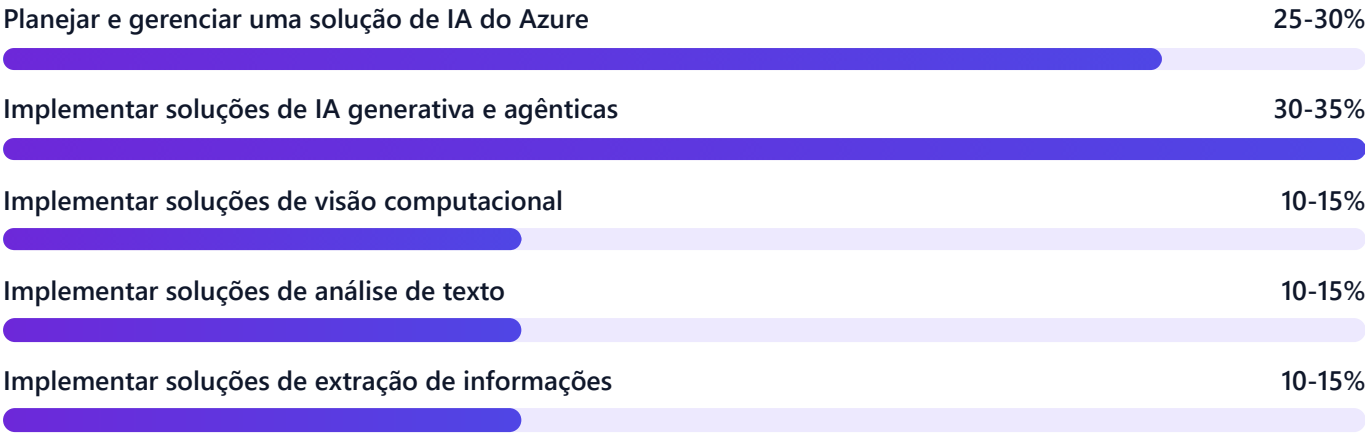
Strecht Simulados

# Resumo de bolso AI-103

Domínios cobrados, as dicas de prova mais importantes e 10 questões comentadas para treinar.

| 300 | 6 | 70% |
| --- | --- | --- |
| questões no curso | provas completas | nota de corte |

## Como é a prova AI-103




Material independente de preparação, sem afiliação ou endosso de Microsoft. As questões são inéditas e não reproduzem a prova real.


### Pronto para o exame AI-103?

Treine com as 300 questões em 6 provas completas: tempo do exame, explicação de cada alternativa e link da documentação para revisar.

**Ver as 6 provas completas e o cupom do mês →**

# Dicas de prova por domínio

## Implementar soluções de IA generativa e agênticas

- Só enviar prompt ao modelo? project.get_openai_client() + responses.create(model=implantação).
- Router com compliance = subconjunto de modelos (dois ou mais para failover).
- mcp_approval_request? Responda com mcp_approval_response (approve e approval_request_id) + previous_response_id.
- ID da conexão em Python = project.connections.get(nome).id.
- Já tem índice no AI Search? Ferramenta Azure AI Search. Só arquivos avulsos? File search.
- API com especificação OpenAPI = ferramenta OpenAPI (anônima, chave ou identidade gerenciada).
- Delegar a outro agente sem workflow = ferramenta A2A.
- Azure Functions como ferramenta MCP = endpoint /runtime/webhooks/mcp.

## Implementar soluções de visão computacional

- Ajuste pontual em vídeo gerado = remix pelo id, uma mudança por vez.
- Regra de marca em imagem = modelo multimodal com as regras nas instruções + saída estruturada.
- Moderar foto enviada por usuário = Content Safety, análise de imagem (severidade 0, 2, 4 ou 6).
- Instrução escondida em imagem = OCR + Prompt Shields para documentos.
- Detalhe pequeno na imagem = detail high (mais tokens).
- Preservar detalhes da imagem de referência = input_fidelity high.
- Ajuste pontual em vídeo gerado = remix do Sora 2.
- Imagem com símbolo de ódio = Content Safety Analyze Image (Hate).

## Planejar e gerenciar uma solução de IA do Azure

- Simular ataques e medir ASR = AI Red Teaming Agent. Riscos de agente (vazamento, ações proibidas) = na nuvem.
- PTU esgotou no pico e não quer comprar mais? Spillover para Standard do mesmo modelo e versão.
- Recursos só privados = pipeline rodando dentro da VNet (runner auto-hospedado).
- Manter a versão e não cair na aposentadoria = OnceCurrentVersionExpired.
- Entendeu o que o cliente quer? Intent Resolution.
- Simular ataques e medir ASR = AI Red Teaming Agent.
- Portão de qualidade no pipeline = ai-agent-evals comparando nome:versão.
- Grande volume, sem pressa e barato = Global Batch (24 h, 50% de desconto, cota separada).

## Implementar soluções de análise de texto

- Termos técnicos errados na transcrição = custom speech (avalie com WER).
- Ruído e jargão em lote = custom speech treinado com áudio; no lote não precisa de endpoint.
- Voz pronuncia errado? SSML com phoneme ou lexicon.
- Translator 2026-06-06: deploymentName = LLM para usar tone e gender; general = NMT.
- Prompt e few-shot não bastaram para o estilo e há milhares de exemplos aprovados? Fine-tuning (SFT).
- Idioma de entrada desconhecido e voz natural ao vivo = Live Interpreter.
- Mascarar dado pessoal antes do LLM = Azure Language PII (texto).
- Transcrição com turnos = Conversation PII; string avulsa = Text PII; PDF ou DOCX = Document PII.

## Implementar soluções de extração de informações

- Foundry IQ no agente = ferramenta MCP + conexão do projeto + Search Index Data Reader.
- PDF escaneado sem texto = imageAction + skill de OCR.
- Texto em imagem dentro do PDF = generateNormalizedImages + OCR + Text Merge.
- Medir a revocação do HNSW = mesma consulta com exhaustive true.
- Tabela que cruza páginas e Markdown para RAG = habilidade Content Understanding.
- Skill de embedding e vectorizer = o MESMO modelo de embeddings.
- Tabela que atravessa páginas no indexador = skill Azure Content Understanding.
- PDF com vários documentos para separar e rotear = contentCategories + analyzerId + other + enableSegment true.

# 10 questões para treinar

Responda antes de olhar o gabarito, no fim do material.

Questão 1 · Implementar soluções de visão computacional

**Uma transportadora gerou com o Sora 2 um vídeo promocional aprovado pela diretoria, mas quer trocar a cor do caminhão e o céu para pôr do sol, mantendo a estrutura, o movimento e o enquadramento da cena original. Como você deve fazer essa edição?**

A. Usar input_reference com um quadro do vídeo e pedir as mudanças em um novo prompt
B. Enviar o vídeo à API de edição de imagens com uma máscara transparente no caminhão
C. Criar um novo vídeo informando remix_video_id do vídeo aprovado e o ajuste no prompt
D. Criar um novo vídeo do zero com um prompt mais detalhado e a mesma semente aleatória

Questão 2 · Implementar soluções de IA generativa e agênticas

**Uma plataforma de streaming quer processar pedidos de suporte assim: um agente com modelo pequeno classifica o pedido; reembolsos simples seguem para um executor com regras de negócio em código; disputas de direitos autorais seguem para um agente com modelo de raciocínio. Como você deve implementar o roteamento no workflow do Microsoft Agent Framework?**

A. Usar arestas switch-case que levam cada mensagem ao executor conforme a classificação
B. Usar arestas de fan-out que enviam cada pedido a cada um dos executores ao mesmo tempo
C. Usar a orquestração Sequential para que cada pedido passe pelos três executores
D. Usar uma implantação do model router para também executar as regras de reembolso

Questão 3 · Implementar soluções de IA generativa e agênticas

**Um agente de reembolsos de uma seguradora chama a função solicitar_aprovacao_gerente, que depende de um gerente aprovar no sistema de alçadas, o que pode levar horas. Nos testes, a execução expira antes de a aplicação devolver a saída da função. Como você deve redesenhar a chamada?**

A. Devolver de imediato um status pendente e consultar a aprovação em um fluxo separado
B. Aumentar o timeout da execução do agente para 24 horas na definição da ferramenta de função
C. Trocar a função por uma ferramenta MCP com require_approval igual a never
D. Aguardar a aprovação dentro da função até o gerente decidir, sem limite de tempo

Questão 4 · Implementar soluções de visão computacional

**Uma fabricante de embalagens tem vídeos longos de treinamento e quer dividi-los automaticamente em trechos por procedimento (setup da máquina, troca de bobina, limpeza), gerando para cada trecho uma descrição e um campo com o nome do procedimento. Ela vai criar um analisador personalizado no Azure Content Understanding. O que você deve configurar?**

A. returnDetails como true para usar cameraShotTimesMs como limites de cada procedimento
B. enableSegment como false e um campo do tipo extract para ler o nome de cada procedimento
C. baseAnalyzerId igual a prebuilt-document e um campo classify com os procedimentos
D. enableSegment como true e contentCategories descrevendo em linguagem natural como segmentar

Questão 5 · Implementar soluções de IA generativa e agênticas

**Uma empresa de mídia vai gerar embeddings de 3 milhões de sinopses com um modelo text-embedding-3-large implantado no seu recurso do Foundry. A equipe busca a menor latência e compatibilidade total com bibliotecas OpenAI que já usa. Qual SDK e endpoint a documentação do Foundry recomenda para esse caso?**

A. O SDK do Agent Framework com FoundryChatClient e um agente dedicado
B. O SDK de uma Foundry Tool específica, como o do Azure Language
C. O SDK do Foundry apontado para o endpoint do projeto em /api/projects
D. O SDK da OpenAI apontado para o endpoint /openai/v1 do recurso

Questão 6 · Implementar soluções de visão computacional

**Uma transportadora quer gerar uma legenda curta para cada uma das 25 fotos tiradas em cada inspeção de carga, enviando as fotos a um modelo GPT multimodal pela API de chat. Os testes com todas as fotos na mesma requisição falham. Qual ajuste você deve fazer?**

A. Dividir as fotos em requisições de no máximo 10 imagens e pedir uma legenda por imagem
B. Mudar a implantação para Global Batch para aceitar mais imagens por requisição
C. Converter as fotos em um PDF de 25 páginas e enviar um único arquivo ao modelo
D. Reduzir a resolução das 25 fotos para 512x512 e manter todas elas na mesma requisição de chat

Questão 7 · Implementar soluções de visão computacional

**Uma universidade quer trocar o fundo das fotos dos professores publicadas no site por um fundo padrão da instituição, com autorização de cada um, usando a API de edição de imagens. Nos testes, os rostos saem levemente diferentes dos originais. A implantação usa o modelo gpt-image-1-mini. O que você deve fazer?**

A. Manter o gpt-image-1-mini e definir input_fidelity como high na solicitação de edição
B. Definir output_format como jpeg e output_compression como 100
C. Usar um modelo gpt-image com suporte a input_fidelity e defini-lo como high
D. Aumentar quality para high e manter o gpt-image-1-mini na edição

Questão 8 · Implementar soluções de IA generativa e agênticas

**Analistas de uma geradora de energia enviam ao agente planilhas CSV com medições horárias de 30 usinas e pedem cálculo de fator de capacidade, comparações entre meses e um gráfico para o relatório. As respostas atuais trazem erros aritméticos porque o modelo calcula sem executar código. Qual ferramenta você deve adicionar ao agente?**

A. O File Search, que indexa as planilhas em um vector store para recuperação
B. O Code Interpreter, que executa Python em ambiente isolado e pode gerar gráficos
C. A ferramenta de pesquisa na web, para buscar fatores de capacidade publicados
D. A ferramenta Azure AI Search, com as planilhas indexadas em um índice híbrido próprio

Questão 9 · Implementar soluções de IA generativa e agênticas

**O assistente de RAG de uma corretora de seguros recebe trechos de apólices no prompt, mas às vezes inventa respostas quando a informação não está nos trechos. Sem trocar o modelo, quais instruções de prompt reduzem esse problema segundo as boas práticas de engenharia de prompt?**

A. Pedir que o modelo deixe os trechos de lado e responda pelas condições gerais que conhece
B. Pedir citações em linha para cada afirmação e responder 'não encontrado' se faltar informação
C. Pedir que o modelo use o próprio conhecimento quando os trechos parecerem incompletos
D. Pedir respostas mais longas e detalhadas para que o modelo explique melhor cada cláusula

Questão 10 · Implementar soluções de extração de informações

**Uma fintech quer preparar milhares de contratos e lâminas de produtos, com tabelas, gráficos e anotações manuscritas, para um agente de RAG. Precisa de uma representação limpa em Markdown, com descrição das figuras, um resumo de cada documento e chunks prontos para embeddings, sem definir campos. Qual analisador você deve usar?**

A. prebuilt-imageSearch do Content Understanding
B. prebuilt-invoice do Content Understanding
C. prebuilt-read do Content Understanding com OCR ativado
D. prebuilt-documentSearch do Content Understanding

# Gabarito comentado

**1. C) Criar um novo vídeo informando remix_video_id do vídeo aprovado e o ajuste no prompt**
Ajustar vídeo gerado mantendo a cena = remix_video_id.

**2. A) Usar arestas switch-case que levam cada mensagem ao executor conforme a classificação**
Rotear por classificação no workflow = arestas switch-case (ou condicionais).

**3. A) Devolver de imediato um status pendente e consultar a aprovação em um fluxo separado**
Aprovação demorada? Status pendente já + polling (a execução expira em 10 min).

**4. D) enableSegment como true e contentCategories descrevendo em linguagem natural como segmentar**
Dividir vídeo por lógica de negócio = enableSegment + contentCategories.

**5. D) O SDK da OpenAI apontado para o endpoint /openai/v1 do recurso**
Embeddings e máxima compatibilidade OpenAI = SDK da OpenAI no /openai/v1.

**6. A) Dividir as fotos em requisições de no máximo 10 imagens e pedir uma legenda por imagem**
Muitas imagens? Até 10 por requisição de chat.

**7. C) Usar um modelo gpt-image com suporte a input_fidelity e defini-lo como high**
Preservar rosto na edição = input_fidelity high (indisponível no gpt-image-1-mini).

**8. B) O Code Interpreter, que executa Python em ambiente isolado e pode gerar gráficos**
Cálculo e gráfico sobre arquivos = Code Interpreter.

**9. B) Pedir citações em linha para cada afirmação e responder 'não encontrado' se faltar informação**
Contra invenção em RAG: citação em linha + 'não encontrado'.

**10. D) prebuilt-documentSearch do Content Understanding**
Documento para RAG em Markdown, com resumo e figuras descritas = prebuilt-documentSearch.


## Pronto para o exame AI-103?

Treine com as 300 questões em 6 provas completas: tempo do exame, explicação de cada alternativa e link da documentação para revisar.

**Ver as 6 provas completas e o cupom do mês →**