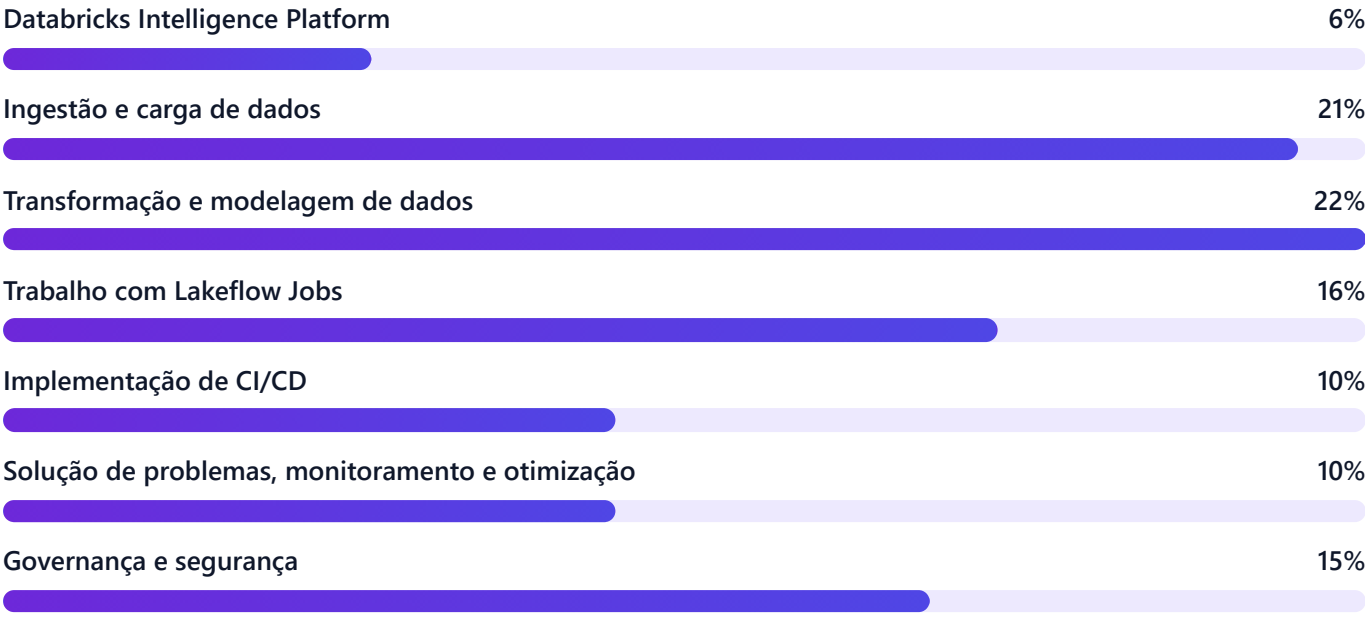
Strecht Simulados

# Resumo de bolso Databricks Data Engineer Associate

Domínios cobrados, as dicas de prova mais importantes e 10 questões comentadas para treinar.

| 270 | 6 | 70% |
| --- | --- | --- |
| questões no curso | provas completas | nota de corte |

# Como é a prova Databricks Data Engineer Associate




Material independente de preparação, sem afiliação ou endosso de Databricks. As questões são inéditas e não reproduzem a prova real.

## Pronto para o exame Databricks Data Engineer Associate?

Treine com as 270 questões em 6 provas completas: tempo do exame, explicação de cada alternativa e link da documentação para revisar.

**Ver as 6 provas completas e o cupom do mês →**

# Dicas de prova por domínio

## Trabalho com Lakeflow Jobs

- Pular tarefa temporariamente sem perdê-la = desabilitar a tarefa.
- Arquivos chegam em horários irregulares = gatilho File arrival.
- Tarefa de alerta/compensação após falha parcial = Run if At least one failed.
- Quais tabelas dispararam o job = {{job.trigger.table_update.updated_tables}}.
- If/else: == e != comparam texto; operadores de ordem comparam números.
- Horário exato de execução = agendamento Advanced (ou cron).
- Pipeline contínuo = tarefa em job contínuo, com Pipeline mode triggered.
- Passar valor calculado entre tarefas = taskValues.set + {{tasks.tarefa.values.chave}}.

## Transformação e modelagem de dados

- Fonte que só cresce + processar cada linha uma vez = streaming table.
- Remover linhas com qualquer nulo = na.drop() (any é o padrão).
- Nulo vira valor padrão = coalesce(coluna, padrão).
- Trocar string vazia por outro valor = na.replace; preencher nulo = na.fill.
- Materialized view com atualização periódica no SQL = SCHEDULE EVERY.
- Linhas idênticas repetidas = distinct().
- Várias regras com descarte = @dp.expect_all_or_drop(dicionário).
- Mais precisão no approx_count_distinct = relativeSD menor.

## Solução de problemas, monitoramento e otimização

- Conflito de bibliotecas = isolar com %pip ou environment; evitar init scripts.
- Visão geral de falhas e erros mais comuns = aba Runs de Jobs & Pipelines.
- Histórico de jobs além de 60 dias = system.lakeflow (365 dias).
- Lacunas na timeline com driver ocupado = código não Spark no driver.
- Suspeita de OOM em executores = testar o dobro de memória por núcleo.
- Max muito maior que o percentil 75 no estágio = skew.
- Volume lido = Input; troca entre executores = Shuffle Read/Write.
- Muitos arquivos pequenos = OPTIMIZE + predictive optimization + layout melhor.

## Governança e segurança

- Externa Delta para gerenciada preservando tudo = ALTER TABLE ... SET MANAGED.

- Criar política ABAC = MANAGE (ou dono) no escopo + EXECUTE na UDF.
- Tabela excluída por engano = UNDROP TABLE dentro do período de recuperação.
- DROP em gerenciada apaga dados (após a recuperação); em externa, só metadados.
- Ler tabela = USE CATALOG + USE SCHEMA + SELECT.
- Alterar dados de tabela = MODIFY.
- Restringir linhas por grupo em uma tabela = função booleana + ALTER TABLE ... SET ROW FILTER.
- Máscara: retorno compatível com o tipo da coluna, uma por coluna.

## Implementação de CI/CD

- Estrutura reaproveitável no bundle = variável type: complex.
- Conflito no Git folder = resolver na UI ou Abort.
- Permissão para todos os recursos do bundle = permissions de nível superior.
- Reset no Git folder = reset --hard + push --force: perde tudo do branch.
- Precedência: --var > BUNDLE_VAR_ > overrides.json > target > default.
- Variável de bundle vinda do CI = BUNDLE_VAR_nome.
- Caminho por usuário e ambiente = ${workspace.current_user.userName} + ${bundle.target}.
- Deploy de bundle em CI = OAuth M2M com entidade de serviço.

## Ingestão e carga de dados

- Testar uma carga do COPY INTO sem gravar = VALIDATE.
- Exatamente uma vez no Auto Loader = estado no checkpoint (RocksDB).
- Criar conexão do Unity Catalog por automação = databricks connections create --json.
- Converter e escolher colunas durante o COPY INTO = FROM (SELECT ... FROM origem).
- Sem CDC, mas com coluna de alteração confiável = conector baseado em consulta (cursor).
- Muitos arquivos em streaming de arquivos = Auto Loader.
- Escolha de ingestão: comece pelo mais gerenciado; desça só se precisar.
- Imagens e PDFs com conteúdo e metadados = binaryFile.

## Databricks Intelligence Platform

- Carga variável na mesma execução = autoscaling (mínimo e máximo).
- Produção = jobs compute ou serverless; all-purpose é para uso interativo.
- Serverless = sem versão fixa, atualizado automaticamente pela Databricks.
- Spill em consultas = cluster size maior; fila de consultas = mais clusters.
- Clássica = conta de nuvem do cliente; serverless = compute plane na conta da Databricks.

- Voltar a uma versão anterior + histórico de alterações + fonte única governada = Delta Lake com Unity Catalog.
- Consumo de negócio e BI = camada gold.
- Acelerar SQL e DataFrames pesados sem mudar código = Photon.

# 10 questões para treinar

Responda antes de olhar o gabarito, no fim do material.

Questão 1 · Trabalho com Lakeflow Jobs

**O job de reprocessamento da Cooperativa Agrícola Vale do Sol tem o job parameter data_ref com valor padrão do dia atual. Hoje a equipe precisa rodá-lo uma vez para 2026-09-30 sem alterar a definição do job. Como fazer pela UI?**

A. Usar Run now with different parameters e informar data_ref=2026-09-30
B. Usar Repair run na última execução e informar o novo data_ref no diálogo
C. Criar um job novo com data_ref fixo e excluí-lo depois da execução
D. Editar o valor padrão de data_ref, executar o job e restaurar o valor depois

Questão 2 · Trabalho com Lakeflow Jobs

**No job de faturamento da Elétrica Vale Norte, a tarefa validar_notas grava a quantidade de notas rejeitadas com dbutils.jobs.taskValues.set(key="rejeitadas", value=total). A tarefa de reprocessamento deve rodar apenas quando houver rejeições. Como montar essa lógica no job?**

A. Criar uma tarefa For each sobre {{tasks.validar_notas.values.rejeitadas}} que rode o reprocessamento por nota
B. Configurar Run if = At least one failed no reprocessamento para que rode quando validar_notas tiver rejeições
C. Adicionar uma tarefa If/else condition com {{tasks.validar_notas.values.rejeitadas}} > 0 e ligar o reprocessamento ao ramo true
D. Definir um gatilho de atualização de tabela na tabela de notas para disparar o reprocessamento ao surgir uma rejeição

Questão 3 · Transformação e modelagem de dados

**Em um Lakeflow pipeline da Distribuidora Água Viva, a streaming table silver_entregas não deve receber registros com cep nulo, mas o pipeline precisa continuar rodando, e a equipe quer acompanhar quantos registros foram descartados. Qual definição atende?**

A. CONSTRAINT cep_valido EXPECT (cep IS NOT NULL) ON VIOLATION FAIL UPDATE
B. CONSTRAINT cep_valido EXPECT (cep IS NOT NULL) ON VIOLATION DROP ROW
C. CONSTRAINT cep_valido EXPECT (cep IS NOT NULL)
D. CONSTRAINT cep_valido CHECK (cep IS NOT NULL)

Questão 4 · Governança e segurança

**Na Operadora Saúde Mais, a coluna telefone da tabela prd.cad.beneficiarios deve aparecer mascarada para os usuários, exceto para o grupo atendimento. A função prd.seg.mascara_tel(tel STRING) RETURNS STRING já existe e usa is_account_group_member. Qual comando aplica a máscara?**

A. ALTER TABLE prd.cad.beneficiarios ALTER COLUMN telefone SET MASK prd.seg.mascara_tel
B. UPDATE prd.cad.beneficiarios SET telefone = prd.seg.mascara_tel(telefone)
C. ALTER TABLE prd.cad.beneficiarios SET ROW FILTER prd.seg.mascara_tel ON (telefone, nome)
D. GRANT SELECT (telefone) ON TABLE prd.cad.beneficiarios TO `atendimento`

Questão 5 · Transformação e modelagem de dados

**Na Rede Escolar Saber Mais, df_notas tem as colunas escola, disciplina e nota. A coordenação quer a média de nota por escola, com a coluna de resultado chamada media_nota. Considerando from pyspark.sql.functions import avg, qual código atende?**

A. df_notas.select(avg("nota").alias("media_nota"), "escola")
B. df_notas.groupBy("escola").agg(avg("nota").alias("media_nota"))
C. df_notas.groupBy("escola").avg("media_nota")
D. df_notas.withColumn("media_nota", avg("nota")).groupBy("escola")

Questão 6 · Trabalho com Lakeflow Jobs

**No job da Rede de Supermercados Família Feliz, uma tarefa de notebook escrita em Python com algumas células SQL foi configurada para rodar em um SQL warehouse serverless e não pôde ser salva assim. Por quê?**

A. SQL warehouses só rodam notebooks escritos inteiramente em SQL, com SQL como linguagem padrão
B. SQL warehouses só rodam notebooks Python quando o warehouse é do tipo pro
C. Notebooks com mais de uma linguagem exigem uma tarefa If/else antes de rodar
D. Notebooks em warehouses precisam estar em um Git folder conectado ao job

Questão 7 · Solução de problemas, monitoramento e otimização

**Um job da Rede de Varejo Moda Já grava uma tabela a partir de uma consulta, e a Spark UI mostra que o estágio de escrita tem algumas tarefas muito maiores que as outras, gerando arquivos grandes demais e pequenos demais. O AQE está ligado. Qual hint a documentação sugere para a escrita?**

A. MERGE
B. BROADCAST
C. REBALANCE
D. COALESCE(1)

Questão 8 · Governança e segurança

**O job de produção da Transportes Rápido Leste roda como a entidade de serviço sp-etl-prod, cujo applicationId é 7c1e9a2b-55d0-4c1f-9e3a-2f6b8d0c4a11. Ela precisa ler a tabela prd.frota.viagens. Como conceder o SELECT para essa entidade em SQL?**

A. GRANT SELECT ON TABLE prd.frota.viagens TO 'sp-etl-prod' AS APPLICATION
B. GRANT SELECT ON TABLE prd.frota.viagens TO JOB 'sp-etl-prod'
C. GRANT SELECT ON TABLE prd.frota.viagens TO `7c1e9a2b-55d0-4c1f-9e3a-2f6b8d0c4a11`
D. GRANT SELECT ON TABLE prd.frota.viagens TO SERVICE_PRINCIPAL sp-etl-prod

Questão 9 · Trabalho com Lakeflow Jobs

**Na Indústria Gráfica Papel Nobre, a tarefa de notebook de um job recebe o parâmetro data_ref, configurado como chave e valor na própria tarefa. Como o código Python do notebook lê esse valor?**

A. dbutils.widgets.get("data_ref")
B. spark.conf.get("data_ref")
C. os.environ["data_ref"]
D. dbutils.jobs.taskValues.get("data_ref")

Questão 10 · Governança e segurança

**Na Seguradora Rede Segura, uma engenheira com MANAGE e SELECT na tabela prd.sin.avisos quer aplicar um filtro de linha com a função prd.seg.f_regiao, criada por outro time. Ela já tem USE CATALOG e USE SCHEMA nos objetos envolvidos, mas a tentativa falha por falta de permissão. Qual privilégio adicional ela precisa?**

A. EXECUTE na função prd.seg.f_regiao
B. MODIFY na tabela prd.sin.avisos
C. REFRESH na tabela prd.sin.avisos
D. APPLY TAG na função prd.seg.f_regiao

# Gabarito comentado

**1. A) Usar Run now with different parameters e informar data_ref=2026-09-30**
Executar uma vez com outro valor = Run now with different parameters.

**2. C) Adicionar uma tarefa If/else condition com {{tasks.validar_notas.values.rejeitadas}} > 0 e ligar o reprocessamento ao ramo true**
Desvio por valor calculado em uma tarefa anterior = If/else condition + task value.

**3. B) CONSTRAINT cep_valido EXPECT (cep IS NOT NULL) ON VIOLATION DROP ROW**
Descartar inválidos e seguir com métricas = EXPECT ... ON VIOLATION DROP ROW.

**4. A) ALTER TABLE prd.cad.beneficiarios ALTER COLUMN telefone SET MASK prd.seg.mascara_tel**
Esconder valor de coluna por grupo = ALTER COLUMN ... SET MASK função.

**5. B) df_notas.groupBy("escola").agg(avg("nota").alias("media_nota"))**
Agregar e nomear = groupBy(...).agg(func(...).alias("nome")).

**6. A) SQL warehouses só rodam notebooks escritos inteiramente em SQL, com SQL como linguagem padrão**
Notebook em SQL warehouse = só se for 100% SQL.

**7. C) REBALANCE**
Partições de saída desequilibradas na escrita = hint REBALANCE.

**8. C) GRANT SELECT ON TABLE prd.frota.viagens TO `7c1e9a2b-55d0-4c1f-9e3a-2f6b8d0c4a11`**
GRANT para entidade de serviço = applicationId entre crases.

**9. A) dbutils.widgets.get("data_ref")**
Parâmetro de tarefa de notebook = dbutils.widgets.get("nome").

**10. A) EXECUTE na função prd.seg.f_regiao**
Aplicar filtro ou máscara = EXECUTE na função + dono (ou MANAGE e SELECT) na tabela.


## Pronto para o exame Databricks Data Engineer Associate?

Treine com as 270 questões em 6 provas completas: tempo do exame, explicação de cada alternativa e link da documentação para revisar.

**Ver as 6 provas completas e o cupom do mês →**