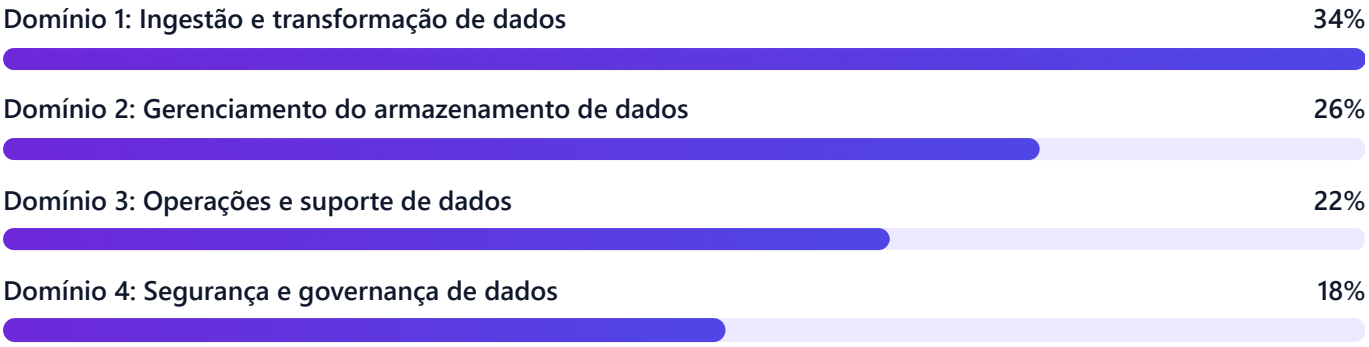
Strecht Simulados

Resumo de bolso DEA-C01

Domínios cobrados, as dicas de prova mais importantes e 10 questões comentadas para treinar.

390	6	72%
questões no curso	provas completas	nota de corte

Como é a prova DEA-C01



Material independente de preparação, sem afiliação ou endosso de Amazon Web Services (AWS). As questões são inéditas e não reproduzem a prova real.

Pronto para o exame DEA-C01?

Treine com as 390 questões em 6 provas completas: tempo do exame, explicação de cada alternativa e link da documentação para revisar.

Ver as 6 provas completas e o cupom do mês →

Dicas de prova por domínio

Domínio 2: Gerenciamento do armazenamento de dados

- Acesso trimestral + leitura em milissegundos + menor custo = S3 Glacier Instant Retrieval.
- Bilhões de vetores, memória limitada e recall menor aceitável = IVF + PQ (faiss, com treino).
- Buscar arquivos no SFTP de um parceiro = conector SFTP do Transfer Family. Parceiro enviando = servidor SFTP.
- Filtros em várias colunas com a mesma importância numa tabela Iceberg = compactação Z-order.
- Crawler em tabela DynamoDB de produção = amostragem + scanning rate baixo.
- Crawler criando uma tabela por pasta com esquemas parecidos = Create a single schema for each S3 path.
- Athena consultando o Glue Data Catalog de outra conta = registrar data source GLUE com catalog-id da conta dona.
- Padrão de acesso desconhecido ou que muda + sem taxa de recuperação = S3 Intelligent-Tiering.

Domínio 3: Operações e suporte de dados

- DAG não aparece no MWAA: veja os logs de DAG processing (erro de importação) no CloudWatch.
- Array em várias linhas no Athena: CROSS JOIN UNNEST. Juntar linhas em array: ARRAY_AGG.
- Quem fez o quê nos últimos 90 dias, sem trilha: Event history do CloudTrail.
- Glue sem espaço em disco no shuffle: shuffle no S3 ou workers maiores.
- Busca de texto e painéis interativos em logs: OpenSearch Service. Consulta pontual no S3: Athena.
- Rastreabilidade de execuções por mais de 90 dias: logging da state machine no CloudWatch Logs (ALL + dados de execução) com retenção.
- Reagir ao fim de um job do Glue: regra do EventBridge para Glue Job State Change.
- Alerta de estatísticas ausentes ou estimativas erradas no Redshift: ANALYZE. Espaço e ordenação: VACUUM.

Domínio 1: Ingestão e transformação de dados

- Esperar aprovação humana ou sistema externo sem polling: .waitForTaskToken + SendTaskSuccess.
- Atualizar aplicação Flink sem perder agregações: restaurar do snapshot.
- Spark serverless com opção visual sem código para ETL: AWS Glue (Glue Studio).
- Reaproveitar uma sequência em vários workflows e esperar seu fim: state machine filha com StartExecution .sync.
- UDF Python lenta no Spark: trocar por funções nativas (ou pandas UDF vetorizada).
- Casar o mesmo cliente em fontes sem chave comum, com ML e sem código: Glue FindMatches.

- Isolar registros malformados sem parar o job do Glue: errorsAsDynamicFrame + limites de erro.
- Glue precisa de driver JDBC diferente do embutido: JAR no S3 + customJdbcDriverS3Path/ClassName.

Domínio 4: Segurança e governança de dados

- Credencial de banco que muda: referencie um segredo do Secrets Manager na conexão, nunca a senha fixa.
- Reduzir uma role ampla ao que foi usado: geração de política do IAM Access Analyzer (atividade do CloudTrail).
- Configuração comum: Parameter Store. Credencial com rotação: Secrets Manager.
- Bucket compartilhado com política enorme: um S3 Access Point por aplicação ou equipe.
- Muitas equipes e recursos que mudam sempre: ABAC com tags (aws:PrincipalTag x tag do recurso).
- Sub-rede privada sem internet acessando S3 ou DynamoDB sem custo extra: gateway endpoint.
- Restringir linhas e colunas da mesma tabela no Lake Formation: data filters (segurança em nível de célula).
- Restringir regiões em toda a organização: SCP com aws:RequestedRegion (exceto serviços globais).

10 questões para treinar

Responda antes de olhar o gabarito, no fim do material.

Questão 1 · Domínio 1: Ingestão e transformação de dados

Um stream do Amazon Data Firehose de uma rede de lojas usa uma função Lambda para transformar os registros antes da entrega no Amazon S3. A contagem diária no S3 está menor que a quantidade enviada, a função não mostra erros de timeout, e a equipe quer saber quais registros não foram entregues e por quê. Onde deve procurar?

A. No buffer do Firehose, que retém os registros com falha por 24 horas para reenvio pelo console
B. No histórico de eventos do AWS CloudTrail, que guarda os registros rejeitados pelo Firehose
C. Na fila de mensagens mortas configurada na função Lambda para invocações assíncronas com falha
D. Na pasta processing-failed do bucket de destino, com o código e a mensagem de erro de cada registro

Questão 2 · Domínio 1: Ingestão e transformação de dados

Cientistas de dados de uma varejista escreveram em pandas um script de limpeza que funciona com amostras, mas falta memória ao processar a base completa de 200 GB em uma única máquina. A equipe quer executar no AWS Glue 4.0 com o mínimo de reescrita, sem aprender a API de DataFrame do Spark. Qual abordagem atende?

A. Usar a pandas API on Spark (pyspark.pandas), que mantém a sintaxe do pandas com execução distribuída
B. Reescrever o script em Scala com RDDs para executar o processamento distribuído nos workers do Glue
C. Executar o script em um job Python shell do Glue com 1 DPU, carregando a base completa em memória
D. Ler a base em lotes de 1 GB com pandas em uma Lambda e unir os resultados parciais em um único arquivo

Questão 3 · Domínio 1: Ingestão e transformação de dados

Um job Spark do AWS Glue 4.0 de uma empresa de cartões processa volumes muito diferentes: nas segundas-feiras precisa de 60 workers, nos outros dias termina bem com 10. Hoje está fixo em 60 workers, e a maior parte da capacidade fica ociosa durante a semana. Como reduzir o custo sem ajustar o job manualmente a cada dia?

A. Ativar o auto scaling do job e definir 60 como número máximo de workers
B. Mudar o job para a classe de execução Flex mantendo os 60 workers fixos
C. Reduzir o job para 10 workers e aceitar o atraso maior nas segundas-feiras
D. Trocar o tipo de worker para G.025X para pagar menos por cada um dos workers

Questão 4 · Domínio 4: Segurança e governança de dados

Uma nova instância do Amazon RDS for PostgreSQL vai alimentar pipelines de dados. A equipe não quer que ninguém conheça ou guarde a senha do usuário master, que deve ficar em um cofre e ser rotacionada sem que a equipe implemente uma função de rotação. Qual é a opção com menor esforço?

A. Guardar a senha master como SecureString no Systems Manager Parameter Store
B. Criar um segredo manualmente e escrever uma Lambda própria para a rotação
C. Definir a senha master no template do CloudFormation como parâmetro NoEcho
D. Habilitar o gerenciamento da senha master pelo RDS no AWS Secrets Manager

Questão 5 · Domínio 1: Ingestão e transformação de dados

Uma stack do AWS CloudFormation de uma empresa de pesquisa cria o bucket da zona raw do data lake, uma tabela do DynamoDB de controle e os jobs do Glue. A equipe vai substituir a stack por outra arquitetura e precisa excluí-la, mas o bucket e a tabela devem continuar existindo com os dados. O que deve ser feito antes da exclusão?

A. Definir UpdateReplacePolicy como Snapshot no bucket e na tabela do template
B. Definir DeletionPolicy como Retain no bucket e na tabela e atualizar a stack
C. Executar a detecção de drift para marcar o bucket e a tabela como externos
D. Ativar a proteção contra encerramento da stack para manter os recursos com dados

Questão 6 · Domínio 1: Ingestão e transformação de dados

Funções Lambda de uma plataforma de ingressos gravam pedidos em um Amazon RDS for MySQL. Em grandes vendas, milhares de execuções simultâneas abrem conexões novas e o banco responde com erro de conexões em excesso. A empresa não quer limitar a concorrência das funções, porque precisa absorver o pico. Qual solução atende?

A. Aumentar o timeout das funções para que elas esperem por uma conexão livre no banco de dados
B. Colocar um Amazon RDS Proxy entre as funções e o banco para compartilhar e reutilizar conexões
C. Criar uma réplica de leitura do RDS e distribuir as gravações das funções entre as duas instâncias
D. Configurar concorrência reservada baixa nas funções para limitar as conexões abertas no banco

Questão 7 · Domínio 1: Ingestão e transformação de dados

Um job do AWS Glue lê uma tabela de 900 milhões de linhas de um Amazon RDS for PostgreSQL por uma conexão JDBC. O Spark UI mostra uma única task fazendo toda a leitura enquanto os demais executors ficam ociosos. Como o engenheiro pode paralelizar a leitura sem alterar o banco de origem?

A. Aumentar o número de workers para que o driver JDBC abra mais cursores na tabela automaticamente
B. Trocar o tipo de worker para G.8X para que a única task de leitura tenha mais memória e CPU
C. Definir hashfield (ou hashexpression) e hashpartitions nas opções de leitura JDBC do Glue
D. Ativar job bookmarks para que o Glue divida a tabela entre linhas já lidas e linhas novas

Questão 8 · Domínio 1: Ingestão e transformação de dados

Uma fintech lê transações de um stream do Kinesis Data Streams com 4 shards por meio de uma função Lambda. Cada lote leva cerca de 2 segundos porque a função consulta um serviço de score de crédito, e a métrica IteratorAge cresce sem parar. A ordem das transações de um mesmo cliente (chave de partição) precisa ser mantida, e a equipe não quer aumentar o número de shards. O que deve ser feito?

A. Configurar concorrência provisionada na função com o dobro do número de shards para aumentar as invocações
B. Aumentar o ParallelizationFactor do event source mapping para processar vários lotes de cada shard ao mesmo tempo
C. Registrar a função como consumidor enhanced fan-out para ampliar a vazão de processamento de cada shard do stream
D. Aumentar o BatchSize para 10.000 registros para que cada invocação leia uma quantidade maior de dados do shard

Questão 9 · Domínio 4: Segurança e governança de dados

Uma empresa adotou o Amazon SageMaker Unified Studio. A equipe do caso de uso de churn (engenheiros, cientistas e analistas) precisa de um espaço comum para compartilhar dados, notebooks e recursos de computação, sem que as demais equipes do mesmo domínio vejam esse trabalho. Como organizar o acesso?

A. Publicar os notebooks no SageMaker Catalog para que todos do domínio possam encontrá-los e assinar
B. Criar um projeto para o caso de uso e adicionar os integrantes como membros do projeto
C. Criar um grupo IAM com acesso a todos os buckets do domínio e incluir os integrantes
D. Criar um domínio separado do Unified Studio para cada integrante da equipe de churn

Questão 10 · Domínio 4: Segurança e governança de dados

No Amazon Redshift, a tabela funcionarios tem 25 colunas, entre elas salario e cpf. A equipe de RH analítico pode consultar todas as colunas, exceto salario e cpf, e a empresa não quer criar nem manter views para isso. Qual comando atende?

A. GRANT SELECT nas 23 colunas permitidas da tabela funcionarios ao grupo de RH analítico
B. CREATE RLS POLICY que retorna nulo nas colunas salario e cpf para o RH analítico
C. GRANT SELECT na tabela funcionarios ao grupo e REVOKE da coluna salario e da coluna cpf
D. GRANT USAGE no schema do RH e SELECT nas tabelas em que não exista a coluna salario

Gabarito comentado

1. D) Na pasta processing-failed do bucket de destino, com o código e a mensagem de erro de cada registro
Registros sumindo no Firehose com Lambda de transformação: olhar a pasta processing-failed no S3.

2. A) Usar a pandas API on Spark (pyspark.pandas), que mantém a sintaxe do pandas com execução distribuída
Código pandas sem memória para o volume total: pandas API on Spark no Glue 4.0+.

3. A) Ativar o auto scaling do job e definir 60 como número máximo de workers
Job do Glue com carga variável e workers ociosos: auto scaling com máximo de workers.

4. D) Habilitar o gerenciamento da senha master pelo RDS no AWS Secrets Manager
Senha master do RDS sem ninguém conhecer e com rotação automática: gerenciamento pelo RDS no Secrets Manager.

5. B) Definir DeletionPolicy como Retain no bucket e na tabela e atualizar a stack
Excluir a stack mas manter bucket ou tabela com dados: DeletionPolicy Retain.

6. B) Colocar um Amazon RDS Proxy entre as funções e o banco para compartilhar e reutilizar conexões
Lambda em pico estourando conexões do RDS sem limitar concorrência: RDS Proxy.

7. C) Definir hashfield (ou hashexpression) e hashpartitions nas opções de leitura JDBC do Glue
Glue lendo tabela JDBC grande em uma task só: hashfield/hashexpression + hashpartitions.

8. B) Aumentar o ParallelizationFactor do event source mapping para processar vários lotes de cada shard ao mesmo tempo
Lambda atrasada no Kinesis, função lenta, sem aumentar shards e mantendo ordem por chave: ParallelizationFactor.

9. B) Criar um projeto para o caso de uso e adicionar os integrantes como membros do projeto
Unified Studio: domínio (organização) > domain units (áreas) > projetos (equipes com membros e recursos).

10. A) GRANT SELECT nas 23 colunas permitidas da tabela funcionarios ao grupo de RH analítico
Esconder colunas de um grupo no Redshift sem view: GRANT SELECT por coluna.

Pronto para o exame DEA-C01?

Treine com as 390 questões em 6 provas completas: tempo do exame, explicação de cada alternativa e link da documentação para revisar.

Ver as 6 provas completas e o cupom do mês →