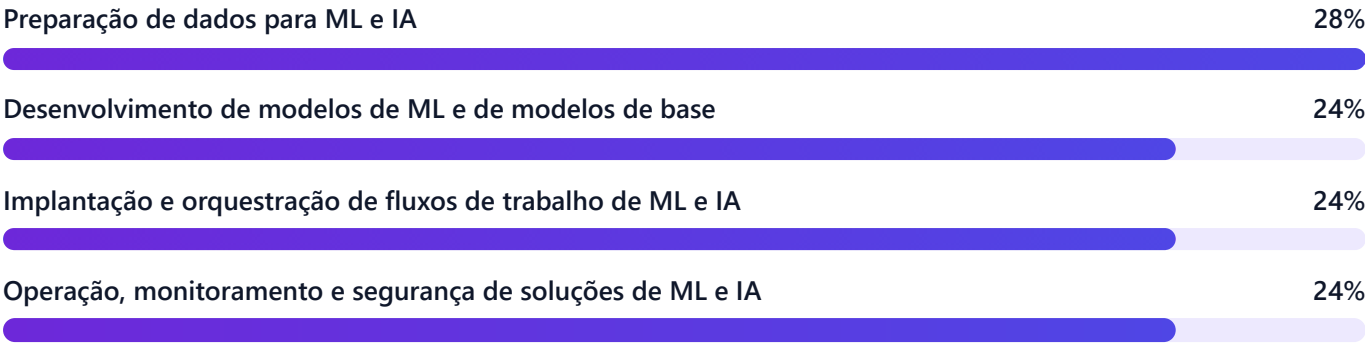
Strecht Simulados

Resumo de bolso MLA-C02

Domínios cobrados, as dicas de prova mais importantes e 10 questões comentadas para treinar.

390	6	72%
questões no curso	provas completas	nota de corte

Como é a prova MLA-C02



Material independente de preparação, sem afiliação ou endosso de Amazon Web Services (AWS). As questões são inéditas e não reproduzem a prova real.

Pronto para o exame MLA-C02?

Treine com as 390 questões em 6 provas completas: tempo do exame, explicação de cada alternativa e link da documentação para revisar.

Ver as 6 provas completas e o cupom do mês →

Dicas de prova por domínio

Implantação e orquestração de fluxos de trabalho de ML e IA

- Mesmo pipeline com valores diferentes por ambiente: parâmetros do pipeline.
- Pipeline refazendo etapas iguais: cache de etapas (CacheConfig).
- Valor de uma stack em outra: Export + Fn::ImportValue.
- Vários agentes especialistas com ponto único de entrada: supervisor que usa os agentes como ferramentas.
- Trocar o modelo ajustado sem trocar o ARN: atualizar o Provisioned Throughput.
- Milhares de modelos parecidos e pouco acessados: endpoint multimodelo.
- Grande volume, sem exigência de baixa latência e com agenda fixa: Batch Transform.
- Infraestrutura como código em Python com componentes reutilizáveis: AWS CDK.

Preparação de dados para ML e IA

- Latência mínima no S3, mesma AZ e dado recriável: S3 Express One Zone.
- Timestamp com padrão por hora e dia: dividir em hora e dia da semana.
- Nem o root pode apagar: Object Lock em modo de conformidade.
- Vários consumidores disputando leitura no Kinesis: enhanced fan-out.
- Faixas interpretáveis com quantidades parecidas: binning por quantis.
- Stream JSON para Parquet no S3 sem código: Data Firehose com conversão de formato.
- Transformer: use o tokenizador do modelo e preserve o texto natural.
- Duplicata sai; valor impossível vira ausente e é tratado.

Desenvolvimento de modelos de ML e de modelos de base (FM)

- Perda oscilando sem convergir: reduza a taxa de aprendizado.
- XGBoost integrado com CSV: alvo na primeira coluna e sem cabeçalho.
- Modelo ajustado esqueceu o que sabia: LoRA e mistura de dados gerais.
- Como a previsão muda conforme um atributo varia: PDP.
- Dependência extra no modo script: requirements.txt no source_dir.
- Variante sombra aprovada: promover para produção.
- Exploração rápida: amostra estratificada; modelo final: dados completos.
- Curvas altas e ainda caindo: treine por mais épocas.

Operação, monitoramento e segurança de soluções de ML e IA

- Mudança estatística sem limiar fixo: detecção de anomalias do Glue Data Quality.
- Custo do Bedrock por equipe na mesma conta: perfil de inferência de aplicação com tags.
- Painel pronto de tokens e latência de FMs: CloudWatch generative AI observability.
- Erro dentro do contêiner do endpoint: CloudWatch Logs em /aws/sagemaker/Endpoints.
- Provar que o log do CloudTrail não foi adulterado: validação de integridade.
- Painéis prontos para aplicativos de IA generativa: observabilidade de IA generativa do CloudWatch.
- Esconder PII e seguir respondendo: Guardrails com mascaramento.
- Documentação de governança do modelo para auditoria: SageMaker Model Cards.

10 questões para treinar

Responda antes de olhar o gabarito, no fim do material.

Questão 1 · Preparação de dados para ML e IA

Uma empresa de logística tem centenas de linhas de código PySpark, com bibliotecas nativas específicas e ajustes finos de configuração do Spark, para processar 50 TB de registros de entregas. A equipe quer migrar esse processamento para a AWS mantendo controle sobre versões do Spark, tipos de instância e configurações do cluster. Qual opção é mais adequada?

A. Reescrever a lógica como receitas do AWS Glue DataBrew
B. Executar os scripts no Amazon EMR com cluster configurado pela equipe
C. Executar os scripts em funções AWS Lambda acionadas a cada novo arquivo no S3
D. Converter o processamento em consultas SQL do Amazon Athena

Questão 2 · Implantação e orquestração de fluxos de trabalho de ML e IA

Uma rede de supermercados usa Batch Transform do SageMaker AI para pontuar um arquivo CSV de clientes. A primeira coluna é o ID do cliente, que não deve ser enviado ao modelo, mas cada previsão precisa sair associada ao ID correspondente no arquivo de saída. Qual configuração atende a esse requisito?

A. Ordenar a saída por ordem alfabética das previsões
B. Executar o job com SplitType=None e um único registro
C. Treinar o modelo novamente incluindo o ID do cliente como feature
D. Usar InputFilter para tirar o ID e JoinSource=Input na saída

Questão 3 · Implantação e orquestração de fluxos de trabalho de ML e IA

Uma edtech hospeda um LLM em um endpoint do SageMaker AI com inference components. O tráfego varia muito e há madrugadas sem nenhuma requisição. A empresa quer escalar as cópias do modelo conforme a demanda e não pagar instâncias com GPU quando não há uso. Qual configuração atende?

A. Configurar o auto scaling pela CPUUtilization das instâncias e manter uma instância ligada a noite toda
B. Definir zero cópias como mínimo no inference component, com target tracking e step scaling
C. Migrar o modelo para um endpoint serverless com GPU e concorrência provisionada nos horários de pico
D. Criar uma programação fixa que dobra as instâncias a cada hora útil e as mantém ligadas de madrugada

Questão 4 · Preparação de dados para ML e IA

Uma rede de supermercados precisa rotular 500 mil imagens de prateleiras para treinar um modelo de classificação de produtos. A empresa quer reduzir o custo e o tempo de rotulagem, mas cada rótulo deve ser conferido por uma pessoa antes de entrar no conjunto de treinamento. Qual abordagem atende a esse requisito?

A. Criar receitas do AWS Glue DataBrew que atribuam a classe de produto a cada imagem
B. Usar os rótulos genéricos do Rekognition DetectLabels direto no treino, sem revisão humana
C. Gerar pré-rótulos das imagens com um FM multimodal do Amazon Bedrock e enviá-los à verificação humana
D. Treinar o Amazon Rekognition Custom Labels com as imagens ainda não rotuladas pela equipe

Questão 5 · Desenvolvimento de modelos de ML e de modelos de base (FM)

Um engenheiro de ML executa um script de treinamento em modo script com o estimador TensorFlow do SageMaker AI e define hiperparâmetros como epochs e batch_size no estimador. O job roda, mas o script continua usando os valores padrão escritos no código. Qual ajuste deve ser feito no script?

A. Ler os hiperparâmetros como argumentos de linha de comando com argparse
B. Ler os hiperparâmetros de uma tabela do Amazon DynamoDB
C. Gravar os hiperparâmetros dentro do arquivo model.tar.gz
D. Definir os hiperparâmetros como tags de recurso do job de treinamento no console

Questão 6 · Preparação de dados para ML e IA

Um modelo de regressão linear de uma rede de supermercados usa a forma de pagamento (dinheiro, débito, crédito, PIX e vale-alimentação) como feature. A equipe codificou as categorias como 1, 2, 3, 4 e 5, e o modelo passou a tratar o vale-alimentação como cinco vezes o dinheiro. Qual codificação é mais adequada?

A. Aplicar transformação logarítmica aos códigos numéricos
B. Aplicar codificação ordinal, ordenando as categorias pelo faturamento médio
C. Aplicar normalização min-max aos códigos de 1 a 5
D. Aplicar one-hot encoding, com uma coluna binária por forma de pagamento

Questão 7 · Operação, monitoramento e segurança de soluções de ML e IA

Uma universidade armazena 200 milhões de vetores de 1.024 dimensões gerados pelo Amazon Titan Text Embeddings V2 em um domínio do Amazon OpenSearch Service, e o custo de memória cresceu. Testes mostraram que vetores de 256 dimensões mantêm precisão aceitável na busca. O que fazer?

A. Aumentar o número de réplicas do índice para distribuir os vetores entre mais nós
B. Regerar os embeddings com 256 dimensões no Titan Text Embeddings V2 e reindexar o acervo
C. Trocar para um modelo de 3.072 dimensões para compensar a perda de precisão esperada na busca
D. Duplicar os vetores em um segundo índice para acelerar as consultas mais frequentes

Questão 8 · Preparação de dados para ML e IA

Uma equipe de engenharia de rede prepara medições de latência para treinar um modelo. Falhas de coleta geraram picos absurdos de milhões de milissegundos. Ela quer detectar e tratar esses outliers por meio de uma ferramenta visual, sem escrever código. Qual opção atende?

A. Aplicar o Amazon Macie para classificar as medições anômalas da rede
B. Aplicar as etapas de outliers do AWS Glue DataBrew, como a de reescala por escore Z
C. Aplicar a codificação one-hot do DataBrew às colunas de latência medida
D. Aplicar normalização min-max mantendo os valores extremos na coluna

Questão 9 · Operação, monitoramento e segurança de soluções de ML e IA

Uma rede de hospitais quer que analistas de dados consultem, pelo Amazon Athena, tabelas do AWS Glue Data Catalog sem ver as colunas com dados pessoais de pacientes, mantendo uma única cópia dos dados. Qual controle atende a esse requisito?

A. Conceder s3:GetObject aos analistas nos prefixos das tabelas
B. Conceder permissões em nível de coluna com o AWS Lake Formation
C. Criar uma cópia das tabelas sem essas colunas para cada analista
D. Criptografar o bucket com SSE-S3 e liberar a leitura aos analistas

Questão 10 · Preparação de dados para ML e IA

Uma transportadora envia leituras de sensores de caminhões ao Amazon Data Firehose, que entrega os dados no Amazon S3. Antes da gravação, cada registro precisa ter campos internos removidos e a unidade de medida padronizada. A empresa não quer gerenciar servidores nem clusters. Qual solução atende a esse requisito?

A. Criar um cluster do Amazon EMR para ler e corrigir os arquivos já gravados no S3
B. Agendar um crawler do AWS Glue sobre o destino no S3
C. Configurar a transformação de dados do Firehose com uma função AWS Lambda
D. Executar um job do AWS Glue DataBrew a cada registro recebido

Gabarito comentado

1. B) Executar os scripts no Amazon EMR com cluster configurado pela equipe
Spark existente com controle fino do cluster: Amazon EMR.

2. D) Usar InputFilter para tirar o ID e JoinSource=Input na saída
Associar previsão ao ID no Batch Transform: InputFilter e JoinSource.

3. B) Definir zero cópias como mínimo no inference component, com target tracking e step scaling
GPU ociosa de madrugada: inference components com escala até zero.

4. C) Gerar pré-rótulos das imagens com um FM multimodal do Amazon Bedrock e enviá-los à verificação humana
Rotular muito com custo menor e conferência humana: pré-rótulos de um FM e revisão por pessoas.

5. A) Ler os hiperparâmetros como argumentos de linha de comando com argparse
Hiperparâmetro ignorado no modo script: ler os argumentos com argparse.

6. D) Aplicar one-hot encoding, com uma coluna binária por forma de pagamento
Categoria sem ordem e com poucos valores: one-hot encoding.

7. B) Regerar os embeddings com 256 dimensões no Titan Text Embeddings V2 e reindexar o acervo
Vetor menor, índice mais barato: reduzir dimensões (e reindexar).

8. B) Aplicar as etapas de outliers do AWS Glue DataBrew, como a de reescala por escore Z
Outliers sem código: receitas do DataBrew.

9. B) Conceder permissões em nível de coluna com o AWS Lake Formation
Esconder colunas sensíveis mantendo uma cópia: Lake Formation em nível de coluna.

10. C) Configurar a transformação de dados do Firehose com uma função AWS Lambda
Transformação leve por registro no Firehose: Lambda de transformação.

Pronto para o exame MLA-C02?

Treine com as 390 questões em 6 provas completas: tempo do exame, explicação de cada alternativa e link da documentação para revisar.

Ver as 6 provas completas e o cupom do mês →